

Ćwiczenie laboratoryjne

9. Implementacja systemów ekspertowych: regułowe systemy wspomagania diagnozy medycznej

1 Implementacja systemów ekspertowych: regułowe systemy wspomagania diagnozy medycznej

1.1 Cel ćwiczenia

Celem ćwiczenia jest zaprojektowanie i implementacja prostego systemu ekspertowego wspomagającego proces diagnozy medycznej na podstawie danych klinicznych. System będzie oparty na zbiorze reguł logicznych typu *IF-THEN* oraz mechanizmie wnioskowania.

Po zakończeniu ćwiczenia student:

- rozumie architekturę systemu ekspertowego,
- potrafi formalizować wiedzę medyczną w postaci reguł,
- implementuje mechanizmy wnioskowania w przód,
- analizuje zalety i ograniczenia systemów regułowych w medycynie.

1.2 Podstawy teoretyczne systemów ekspertowych

System ekspertowy to program komputerowy, który naśladuje sposób rozumowania eksperta w wąskiej dziedzinie (np. diagnostyce chorób). Klasyczny system ekspertowy składa się z:

- bazy wiedzy (reguły, fakty),
- bazy faktów (dane pacjenta),
- mechanizmu wnioskowania,
- interfejsu użytkownika.

Reguły decyzyjne

Reguła ekspertowa ma postać:

$$\text{IF } C_1 \wedge C_2 \wedge \dots \wedge C_n \text{ THEN } H,$$

gdzie:

- C_i – warunki (objawy, wyniki badań),
- H – hipoteza diagnostyczna (np. choroba).

Przykład reguły medycznej:

$$\text{IF SBP} \geq 140 \wedge \text{DBP} \geq 90 \text{ THEN Hypertension.}$$

Wnioskowanie w przód (forward chaining)

Wnioskowanie w przód polega na iteracyjnym stosowaniu reguł, których warunki są spełnione przez aktualną bazę faktów.

Formalnie:

$$F_{t+1} = F_t \cup \{H \mid \exists r : \text{Premise}(r) \subseteq F_t\},$$

gdzie:

- F_t – zbiór faktów w kroku t ,
- H – wniosek reguły r .

Proces trwa aż do osiągnięcia punktu stałego:

$$F_{t+1} = F_t.$$

Reguły z wagami (pewność)

W praktyce medycznej reguły mogą mieć stopień pewności:

$$\text{IF } C \text{ THEN } H \quad [w],$$

gdzie $w \in [0, 1]$ oznacza wiarygodność reguły.

Agregacja pewności może być realizowana np. jako:

$$\mu(H) = \max_i w_i \cdot \mu(C_i).$$

1.3 Dane wejściowe systemu

System ekspertowy będzie pracował na uproszczonych danych pacjenta:

- wiek,
- BMI,
- ciśnienie skurczowe (SBP),
- ciśnienie rozkurczowe (DBP),
- poziom glukozy.

Dane te traktujemy jako fakty początkowe w bazie faktów.

1.4 Implementacja systemu ekspertowego w Pythonie

Reprezentacja reguł

```
rules = [  
    {  
        "if": lambda p: p["systolic_bp"] >= 140 and p["diastolic_bp"] >= 90,  
        "then": "Hypertension",  
        "weight": 0.9  
    },  
    {  
        "if": lambda p: p["bmi"] >= 30,  
        "then": "Obesity",  
        "weight": 0.8  
    },  
    {  
        "if": lambda p: p["glucose"] >= 126,  
        "then": "Diabetes",  
        "weight": 0.85  
    },  
    {  
        "if": lambda p: p["age"] >= 65 and p["systolic_bp"] >= 140,  
        "then": "High cardiovascular risk",  
        "weight": 0.7  
    }  
]
```

Mechanizm wnioskowania

```
def expert_system(patient, rules):  
    conclusions = {}  
  
    for rule in rules:  
        if rule["if"](patient):  
            diagnosis = rule["then"]  
            weight = rule["weight"]  
            conclusions[diagnosis] = max(  
                conclusions.get(diagnosis, 0), weight  
            )  
  
    return conclusions
```

Przykład użycia

```
patient = {  
    "age": 68,  
    "bmi": 31.2,  
    "systolic_bp": 155,  
    "diastolic_bp": 95,  
    "glucose": 110  
}
```

```
}
```

```
results = expert_system(patient, rules)

for diagnosis, confidence in results.items():
    print(f"{diagnosis}: confidence={confidence}")
```

Przykładowy wynik:

```
Hypertension: confidence=0.9
Obesity: confidence=0.8
High cardiovascular risk: confidence=0.7
```

1.5 Interpretacja wyników

System ekspertowy może zwrócić wiele wniosków jednocześnie. Każdy z nich jest opatrzone wagą, która:

- nie jest prawdopodobieństwem klinicznym,
- odzwierciedla siłę reguły,
- pozwala na hierarchizację zaleceń.

W praktyce klinicznej system taki pełni rolę:

narzędzia wspomagającego decyzję lekarza, a nie jej zastępującego.

1.6 Ograniczenia systemów regułowych

- brak uczenia się na nowych danych,
- trudność w skalowaniu liczby reguł,
- brak obsługi niepewności statystycznej,
- podatność na sprzeczne reguły.

Z tego względu systemy ekspertowe są często łączone z modelami ML w architekturach hybrydowych (Expert System + ML).

2 Reguły rozmyte (fuzzy rules) w systemach ekspertowych

2.1 Motywacja stosowania logiki rozmytej w medycynie

Klasyczne systemy ekspertowe oparte na regułach logicznych typu *IF-THEN* operują na wartościach binarnych (prawda/fałsz). W praktyce medycznej wiele pojęć ma jednak charakter nieostry, np.

- „wysokie ciśnienie”,

- „podwyższony poziom glukozy”,
- „pacjent w podeszłym wieku”.

Logika rozmyta (*fuzzy logic*) umożliwia modelowanie takich pojęć poprzez wprowadzenie **stopnia przynależności**, co pozwala na bardziej realistyczne odwzorowanie procesu decyzyjnego lekarza.

2.2 Zbiory rozmyte i funkcje przynależności

Zbiór rozmyty A w przestrzeni X definiowany jest jako funkcja:

$$\mu_A : X \rightarrow [0, 1],$$

gdzie $\mu_A(x)$ określa stopień przynależności elementu x do zbioru A .

W kontekście danych klinicznych:

$$\mu_{\text{SBP_high}}(x) = 0.8$$

oznacza, że wartość ciśnienia skurczowego x jest „wysoka” w stopniu 0.8.

Najczęściej stosowane funkcje przynależności to:

- trójkątne (triangular),
- trapezowe (trapezoidal),
- gaussowskie.

Przykład funkcji trójkątnej:

$$\mu(x; a, b, c) = \begin{cases} 0 & x \leq a, \\ \frac{x-a}{b-a} & a < x < b, \\ \frac{c-x}{c-b} & b \leq x < c, \\ 0 & x \geq c. \end{cases}$$

2.3 Reguły rozmyte

Reguła rozmyta ma postać:

$$\text{IF } X_1 \text{ is } A_1 \wedge X_2 \text{ is } A_2 \text{ THEN } Y \text{ is } B,$$

gdzie:

- X_i – zmienne wejściowe (np. SBP, DBP, wiek),
- A_i – zbiory rozmyte (np. wysokie, graniczne),
- Y – zmienna wyjściowa (np. ryzyko),
- B – zbiór rozmyty wyjścia.

Przykład reguły klinicznej:

$$\text{IF SBP is high OR DBP is high THEN risk is high.}$$

2.4 Operatory logiczne w logice rozmytej

W logice rozmytej klasyczne operatory logiczne są zastąpione operacjami na stopniach przynależności:

- **AND:**

$$\mu_{A \wedge B}(x) = \min(\mu_A(x), \mu_B(x)),$$

- **OR:**

$$\mu_{A \vee B}(x) = \max(\mu_A(x), \mu_B(x)),$$

- **NOT:**

$$\mu_{\neg A}(x) = 1 - \mu_A(x).$$

Takie podejście umożliwia płynne przejścia pomiędzy stanami klinicznymi zamiast sztywnych progów decyzyjnych.

2.5 Wnioskowanie typu Mamdani

Najczęściej stosowanym mechanizmem wnioskowania w systemach rozmytych jest **wnioskowanie Mamdaniego**, które składa się z czterech etapów:

1. **Fuzzification** – obliczenie stopni przynależności wejść.
2. **Ewaluacja reguł** – wyznaczenie siły aktywacji reguł.
3. **Implikacja** – przycięcie zbioru wyjściowego reguły:

$$\mu_{B'}(y) = \min(\alpha, \mu_B(y)),$$

gdzie α jest siłą reguły.

4. **Agregacja** – połączenie wyników wszystkich reguł:

$$\mu_{\text{agg}}(y) = \max_i \mu_{B'_i}(y).$$

2.6 Defuzyfikacja

Aby uzyskać pojedynczą wartość liczbową (np. poziom ryzyka), stosuje się proces defuzyfikacji. Najczęściej wykorzystywana jest metoda środka ciężkości (centroid):

$$y^* = \frac{\int y \cdot \mu_{\text{agg}}(y) dy}{\int \mu_{\text{agg}}(y) dy}.$$

W kontekście medycznym y^* może oznaczać np. końcowy wskaźnik ryzyka w skali 0–100.

2.7 Interpretacja kliniczna reguł rozmytych

System oparty na regułach rozmytych:

- nie podejmuje decyzji binarnych,
- pozwala na stopniową ocenę ryzyka,
- jest bardziej odporny na szum danych,
- lepiej odzwierciedla rozumowanie eksperta klinicznego.

Przykładowa interpretacja:

„Ryzyko nadciśnienia jest wysokie, ponieważ ciśnienie skurczowe jest wysokie w stopniu 0.8, a rozkurczowe w stopniu 0.6, co aktywuje regułę wysokiego ryzyka z dużą siłą.”

2.8 Zastosowanie w systemach hybrydowych

Reguły rozmyte są często integrowane z modelami uczenia maszynowego, tworząc systemy hybrydowe:

System ekspertowy + ML + XAI.

Takie podejście umożliwia:

- połączenie wiedzy eksperckiej z danymi,
- zwiększenie interpretowalności modeli SI,
- spełnienie wymogów regulacyjnych w medycynie.

3 Rozwinięcie systemu o wyjaśnianie „dlaczego” (explainable expert system)

3.1 Motywacja i znaczenie wyjaśnialności

W systemach wspomagania decyzji medycznych kluczowe znaczenie ma nie tylko poprawność wnioskowania, lecz również możliwość jego zrozumienia przez użytkownika (lekarza, analityka, audytora). System ekspertowy powinien zatem odpowiadać nie tylko na pytanie:

„Jaka jest diagnoza?”

ale również:

„Dlaczego system doszedł do takiego wniosku?”

Wyjaśnialność (*Explainable AI*, *XAI*) jest szczególnie istotna w medycynie ze względu na:

- odpowiedzialność prawną i kliniczną,
- zaufanie użytkowników do systemu,
- możliwość walidacji decyzji,
- wymogi regulacyjne (np. RODO, AI Act).

3.2 Źródła wyjaśnienia w systemie ekspertowym

W przeciwieństwie do modeli czysto statystycznych, system ekspertowy oparty na regułach posiada naturalne elementy umożliwiające generowanie wyjaśnień:

- jawne reguły decyzyjne,
- stopnie przynależności zbiorów rozmytych,
- siłę aktywacji reguł,
- mechanizm agregacji wniosków.

Dzięki temu możliwe jest konstruowanie wyjaśnień typu:

„Reguła X została aktywowana, ponieważ warunek A był spełniony w stopniu 0.8, a warunek B w stopniu 0.6.”

3.3 Formalny opis wyjaśnienia

Dla reguły rozmytej:

IF X_1 is $A_1 \wedge X_2$ is A_2 THEN Y is B ,

jej siła aktywacji α wyznaczana jest jako:

$$\alpha = \min(\mu_{A_1}(x_1), \mu_{A_2}(x_2)).$$

Wyjaśnienie reguły może być zatem zapisane jako trójka:

$$\mathcal{E} = (r, \alpha, \mathcal{C}),$$

gdzie:

- r – identyfikator reguły,
- α – siła reguły,
- \mathcal{C} – zbiór stopni przynależności warunków wejściowych.

3.4 Wyjaśnienie lokalne (dla pojedynczego pacjenta)

Wyjaśnienie lokalne dotyczy konkretnego przypadku klinicznego. Dla pacjenta p system może wskazać:

- które reguły zostały aktywowane,
- w jakim stopniu każda z nich wpłynęła na wynik,
- które cechy miały największe znaczenie.

Przykład interpretacji:

„Ryzyko nadciśnienia oceniono jako wysokie, ponieważ:

- ciśnienie skurczowe było wysokie w stopniu 0.82,
- ciśnienie rozkurczowe było wysokie w stopniu 0.61,
- reguła R1 (wysokie SBP lub DBP) została aktywowana z siłą 0.82 i miała największy wkład w końcowy wynik.”

3.5 Udział reguł w końcowej decyzji

Po etapie implikacji i agregacji możliwe jest oszacowanie wkładu każdej reguły w końcowy zbiór wyjściowy, np. poprzez pole pod przyciętym zbiorem rozmytym:

$$\text{Contribution}_i = \frac{\int \mu_{B'_i}(y) dy}{\sum_j \int \mu_{B'_j}(y) dy}.$$

Taki wskaźnik pozwala na:

- rangowanie reguł według wpływu,
- identyfikację dominujących przesłanek decyzyjnych,
- wykrywanie konfliktów pomiędzy regułami.

3.6 Wyjaśnienie globalne

Poza wyjaśnieniami lokalnymi system ekspertowy może generować wyjaśnienia globalne, opisujące ogólne zachowanie systemu:

- które reguły są najczęściej aktywowane,
- które cechy dominują w procesie decyzyjnym,
- jakie kombinacje warunków prowadzą do wysokiego ryzyka.

Wyjaśnienia globalne są szczególnie przydatne:

- podczas walidacji systemu,
- w audytach bezpieczeństwa i jakości,
- w analizie zgodności z wiedzą kliniczną.

3.7 Znaczenie wyjaśnialnych systemów ekspertowych w medycynie

Explainable Expert Systems:

- zwiększają zaufanie do systemów SI,
- ułatwiają współpracę lekarz–system,
- umożliwiają analizę błędów i przypadków granicznych,
- spełniają wymagania etyczne i regulacyjne.

W praktyce klinicznej system ekspertowy z modułem wyjaśnień pełni rolę

transparentnego asystenta decyzyjnego,

a nie nieprzejrzystej „czarnej skrzynki”.

3.8 Podsumowanie

Rozszerzenie systemu ekspertowego o mechanizmy wyjaśniania pozwala na:

- zachowanie interpretowalności decyzji,
- formalne uzasadnianie wniosków diagnostycznych,
- lepszą integrację systemów ekspertowych z praktyką medyczną.

Połączenie reguł rozmytych z wyjaśnieniami stanowi solidną podstawę dla bezpiecznych i odpowiedzialnych systemów sztucznej inteligencji w medycynie.

4 Warianty zadań laboratoryjnych – systemy ekspertowe

We wszystkich wariantach należy korzystać z jednego wspólnego zbioru danych `pacjenci_demo_system_ekspertowy.csv`, zawierającego przykładowe dane pacjentów: wiek, BMI, poziom glukozy oraz ciśnienie tętnicze.

Każdy wariant składa się z trzech etapów:

1. wnioskowanie na podstawie klasycznych reguł (logika binarna),
2. wnioskowanie na podstawie reguł rozmytych (fuzzy),
3. wyjaśnialne wnioskowanie („dlaczego?”).

Wariant 1: Nadciśnienie tętnicze

- Klasyczne reguły: IF SBP \geq 140 AND DBP \geq 90 THEN Hypertension.
- Reguły rozmyte: zbiory „SBP wysokie”, „DBP wysokie”.
- Wyjaśnienie: która reguła była dominująca dla danego pacjenta.

Wariant 2: Przypadki graniczne nadciśnienia

- Klasyczne reguły: analiza pacjentów niespełniających progów.
- Reguły rozmyte: częściowa aktywacja reguł.
- Wyjaśnienie: dlaczego ryzyko nie zostało zaklasyfikowane jako wysokie.

Wariant 3: Ocena ryzyka sercowo–naczyniowego

- Klasyczne reguły: wiek \geq 65 AND SBP \geq 140.
- Reguły rozmyte: „wiek podeszły”, „SBP graniczne”.
- Wyjaśnienie: wpływ wieku na końcową decyzję.

Wariant 4: Diagnostyka otyłości

- Klasyczne reguły: $BMI \geq 30$.
- Reguły rozmyte: „BMI podwyższone” vs „BMI wysokie”.
- Wyjaśnienie: stopień przynależności BMI do zbiorów rozmytych.

Wariant 5: Ocena ryzyka metabolicznego

- Klasyczne reguły: $BMI \geq 30$ OR $glucose \geq 126$.
- Reguły rozmyte: agregacja wielu czynników ryzyka.
- Wyjaśnienie: który czynnik miał największy wpływ.

Wariant 6: Cukrzyca typu 2

- Klasyczne reguły: $glucose \geq 126$.
- Reguły rozmyte: „glukoza podwyższona” i „wysoka”.
- Wyjaśnienie: siła reguły cukrzycowej.

Wariant 7: Prediabetes

- Klasyczne reguły: $100 \leq glucose < 126$.
- Reguły rozmyte: płynne przejście normy w cukrzycę.
- Wyjaśnienie: konflikt reguł i jego rozwiązanie.

Wariant 8: Pacjent geriatryczny

- Klasyczne reguły: $wiek \geq 70$.
- Reguły rozmyte: stopniowa ocena „podeszłego wieku”.
- Wyjaśnienie: wpływ wieku na ocenę ryzyka.

Wariant 9: Pacjent młody z podwyższonym SBP

- Klasyczne reguły: $SBP \geq 140$.
- Reguły rozmyte: kompensacja wieku i ciśnienia.
- Wyjaśnienie: dlaczego ryzyko nie zostało eskalowane.

Wariant 10: Wieloczynnikowe wnioskowanie

- Klasyczne reguły: oddzielne reguły dla BMI, SBP, glukozy.
- Reguły rozmyte: jednoczesna aktywacja wielu reguł.
- Wyjaśnienie: ranking reguł według wpływu.

Wariant 11: Konflikt reguł decyzyjnych

- Klasyczne reguły: sprzeczne wnioski (low vs high risk).
- Reguły rozmyte: łagodzenie konfliktu przez stopnie przynależności.
- Wyjaśnienie: uzasadnienie wyboru decyzji końcowej.

Wariant 12: Analiza kontrfaktyczna

- Klasyczne reguły: zmiana progu powoduje zmianę decyzji.
- Reguły rozmyte: płynna zmiana wyniku.
- Wyjaśnienie: „co należy zmienić, aby obniżyć ryzyko”.

Wariant 13: Przypadki skrajne

- Klasyczne reguły: bardzo wysokie SBP i DBP.
- Reguły rozmyte: pełna aktywacja zbiorów „wysokie”.
- Wyjaśnienie: maksymalna siła reguł.

Wariant 14: Porównanie systemów

- Klasyczne reguły: decyzja binarna.
- Reguły rozmyte: skala ryzyka 0–100.
- Wyjaśnienie: różnice interpretacyjne.

Wariant 15: Kompleksowy system ekspertowy

- Klasyczne reguły: pełny zestaw reguł diagnostycznych.
- Reguły rozmyte: integracja wszystkich zmiennych.
- Wyjaśnienie: raport decyzyjny dla lekarza.

Uwaga organizacyjna. Wszystkie warianty należy realizować na tym samym pliku danych, zmieniając jedynie definicje reguł oraz sposób ich interpretacji.