



Uniwersytet
Bielsko-Bialski

Prognozowanie parametrów zdrowotnych pacjentów

Zadanie OPT

Sprawozdanie z ćwiczeń
Nauka o Danych II

Data wykonania:
28.06.2025

Autor:
Bartosz Bieniek 058085

1. Cel ćwiczenia

Zadanie składa się z trzech części:

Eksperyment numeryczny: Zbadanie wpływu współczynnika uczenia na zachowanie algorytmu optymalizacji.

Analiza alternatywnej funkcji celu: Przetestowanie działania algorytmu optymalizacji na funkcji celu o bardziej złożonym (nieliniowym) charakterze.

Zastosowanie sieci neuronowej: Implementacja sieci MLP do klasyfikacji zbioru MNIST oraz monitorowanie procesu treningu za pomocą TensorBoard.

Szczegóły:

Zbadać wpływ wartości współczynnika uczenia: $\eta = 0.01, 0.001, 0.0001$.

Przetestować funkcję celu:

$$f(x,y)=x^4+y^4-2x^2y$$

$$f(x,y)=x^4+y^4-2x^2y$$

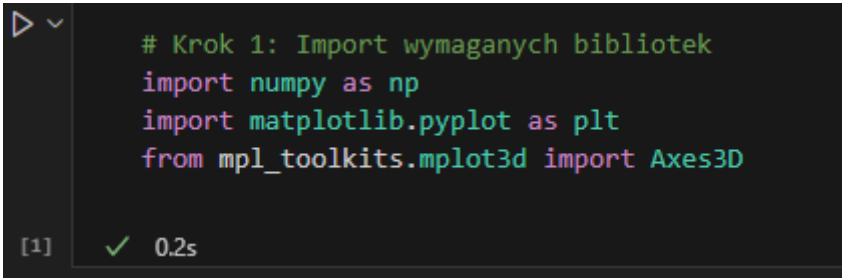
Zaimplementować klasyfikator MLP dla zbioru MNIST i monitorować proces uczenia w TensorBoard.

Zadania umieścić na [Github](#).

2. Przebieg ćwiczenia

1. Import bibliotek:

Zaimportowano niezbędne biblioteki do przeprowadzenia eksperymentów numerycznych oraz wizualizacji wyników. Wykorzystano numpy do obliczeń macierzowych i różniczkowych oraz matplotlib do tworzenia wykresów dwuwymiarowych i trójwymiarowych.



```
# Krok 1: Import wymaganych bibliotek
import numpy as np
import matplotlib.pyplot as plt
from mpl_toolkits.mplot3d import Axes3D

[1] ✓ 0.2s
```

Rys. 1. Import bibliotek

2. Definicja funkcji celu i gradientu:

Zdefiniowano nieliniową funkcję celu postaci $f(x,y)=x^4+y^4-2x^2y$ oraz wyprowadzono analityczne wyrażenia na jej gradient. Funkcja ta charakteryzuje się silną nieliniowością i wieloma ekstremami lokalnymi, co czyni ją wymagającą z punktu widzenia optymalizacji.

```
# Krok 2: Definicja funkcji celu i jej gradientu
def f(x, y):
    return x**4 + y**4 - 2 * x**2 * y

def grad_f(x, y):
    df_dx = 4 * x**3 - 4 * x * y
    df_dy = 4 * y**3 - 2 * x**2
    return np.array([df_dx, df_dy])
```

[2] ✓ 0.0s

Rys. 2. Definicja funkcji celu i gradientu.

3. Implementacja algorytmu gradientowego

Zaimplementowano algorytm gradientowego spadku, który w kolejnych iteracjach aktualizował pozycję punktu na podstawie wartości gradientu i współczynnika uczenia. Zapisano kolejne punkty trajektorii, aby umożliwić późniejszą analizę zbieżności.

```
# Krok 3: Implementacja algorytmu gradientowego
def gradient_descent(eta, steps, start):
    path = [start]
    point = np.array(start, dtype=float)

    for _ in range(steps):
        grad = grad_f(point[0], point[1])
        point = point - eta * grad
        path.append(point.copy())
    return np.array(path)
```

[3] ✓ 0.0s

Rys. 3. Implementacja algorytmu gradientowego

4. Eksperyment z różnymi wartościami współczynnika uczenia:

Przeprowadzono eksperymenty z trzema wartościami współczynnika uczenia: $\eta = 0.01$, 0.001 oraz 0.0001 . Dla każdej wartości zarejestrowano ścieżkę spadku gradientowego, co umożliwiło ocenę wpływu tempa uczenia na przebieg optymalizacji.

```

# Krok 4: Wykonanie eksperymentu dla różnych eta
etas = [0.01, 0.001, 0.0001]
paths = {}

for eta in etas:
    path = gradient_descent(eta=eta, steps=100, start=[1.0, 1.0])
    paths[eta] = path

```

✓ 0.0s

Rys. 4. Eksperyment z różnymi wartościami współczynnika uczenia

5. Wizualizacja trajektorii optymalizacji:

Wygenerowano wykres konturowy funkcji celu wraz z trajektoriami optymalizacji dla różnych wartości eta. Wykres pozwolił zobaczyć różnice w szybkości zbieżności oraz zachowaniu algorytmu przy różnych krokach uczenia.

```

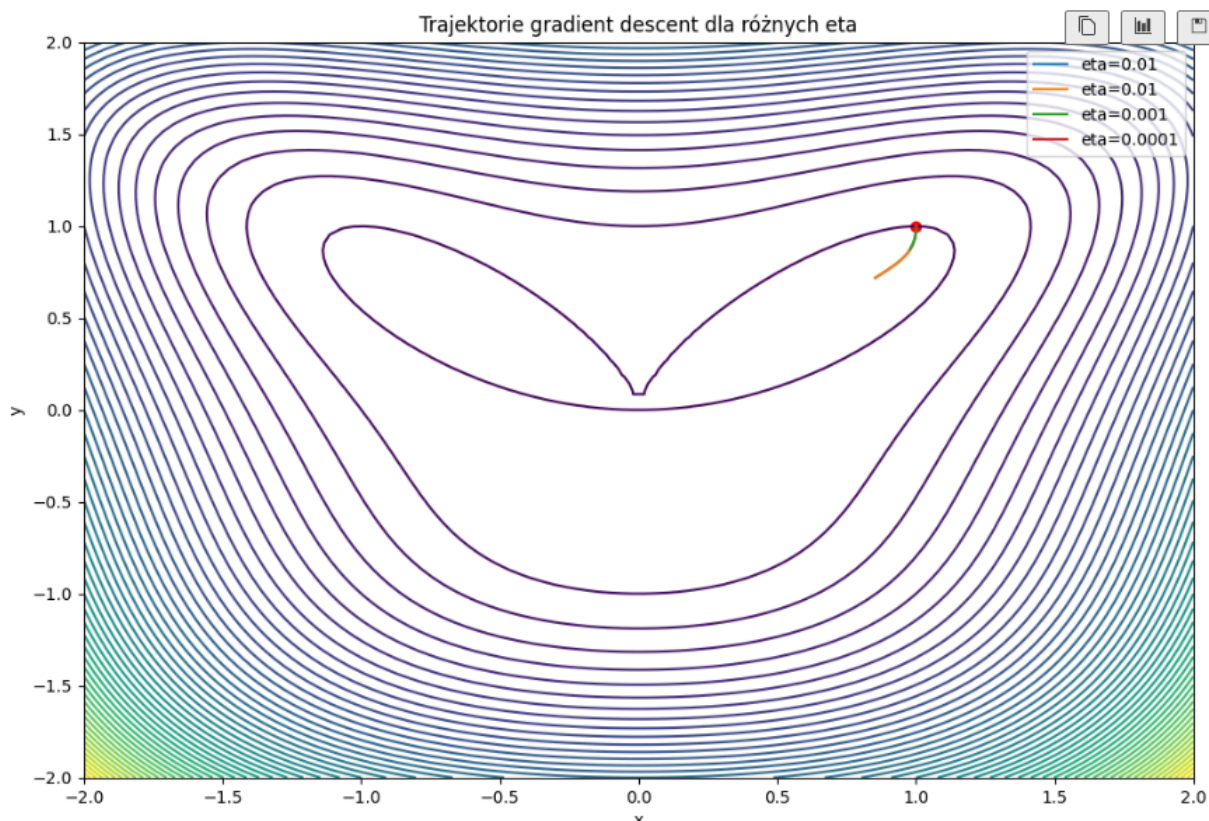
# Krok 5: Wizualizacja trajektorii optymalizacji
x = np.linspace(-2, 2, 100)
y = np.linspace(-2, 2, 100)
X, Y = np.meshgrid(x, y)
Z = f(X, Y)

plt.figure(figsize=(12, 8))
for eta, path in paths.items():
    plt.contour(X, Y, Z, levels=50)
    plt.plot(path[:, 0], path[:, 1], label=f"eta={eta}")
    plt.scatter(path[0, 0], path[0, 1], color='red') # start
    plt.title("Trajektorie gradient descent dla różnych eta")
    plt.xlabel("x")
    plt.ylabel("y")
    plt.legend()
    break # tylko jedna siatka konturów
for eta, path in paths.items():
    plt.plot(path[:, 0], path[:, 1], label=f"eta={eta}")
plt.legend()
plt.show()

```

✓ 0.2s

Rys. 5. Wizualizacja trajektorii optymalizacji (kod)



Rys. 6. Wizualizacja trajektorii optymalizacji

6. Przygotowanie środowiska do pracy z MNIST:

Zaimportowano biblioteki torch, torchvision i tensorboard. Przygotowano środowisko do dalszej pracy z siecią neuronową MLP oraz monitorowania postępów treningu.

```
# Krok 6: Import bibliotek do MNIST i TensorBoard
import torch
import torch.nn as nn
import torch.optim as optim
from torchvision import datasets, transforms
from torch.utils.tensorboard import SummaryWriter
```

✓ 11.7s Pyth

Rys. 7. Przygotowanie środowiska do pracy z MNIST

7. Przygotowanie danych MNIST:

Pobrano zbiór danych MNIST i przygotowano go do treningu w postaci tensora. Dla zbiorów treningowego i testowego zastosowano transformację do postaci tensora i ustawiono parametry ładowania danych (batch size, shuffle).

```
# Krok 7: Przygotowanie danych MNIST
transform = transforms.ToTensor()
train_loader = torch.utils.data.DataLoader(
    datasets.MNIST('.', train=True, download=True, transform=transform),
    batch_size=64,
    shuffle=True
)
test_loader = torch.utils.data.DataLoader(
    datasets.MNIST('.', train=False, transform=transform),
    batch_size=1000,
    shuffle=False
)
```

7] ✓ 10.6s

100%	9.91M/9.91M	[00:05<00:00, 1.76MB/s]
100%	28.9k/28.9k	[00:00<00:00, 250kB/s]
100%	1.65M/1.65M	[00:01<00:00, 1.20MB/s]
100%	4.54k/4.54k	[00:00<00:00, 4.55MB/s]

Rys. 8. Przygotowanie danych MNIST

8. Definicja architektury sieci MLP:

Zaprojektowano prostą sieć neuronową typu MLP składającą się z jednej warstwy ukrytej z funkcją aktywacji ReLU oraz wyjściowej warstwy klasyfikującej 10 klas cyfr. Model został przygotowany do pracy na urządzeniu CPU lub GPU.

```
# Krok 8: Definicja sieci MLP
class MLP(nn.Module):
    def __init__(self):
        super().__init__()
        self.fc1 = nn.Linear(28*28, 128)
        self.relu = nn.ReLU()
        self.fc2 = nn.Linear(128, 10)

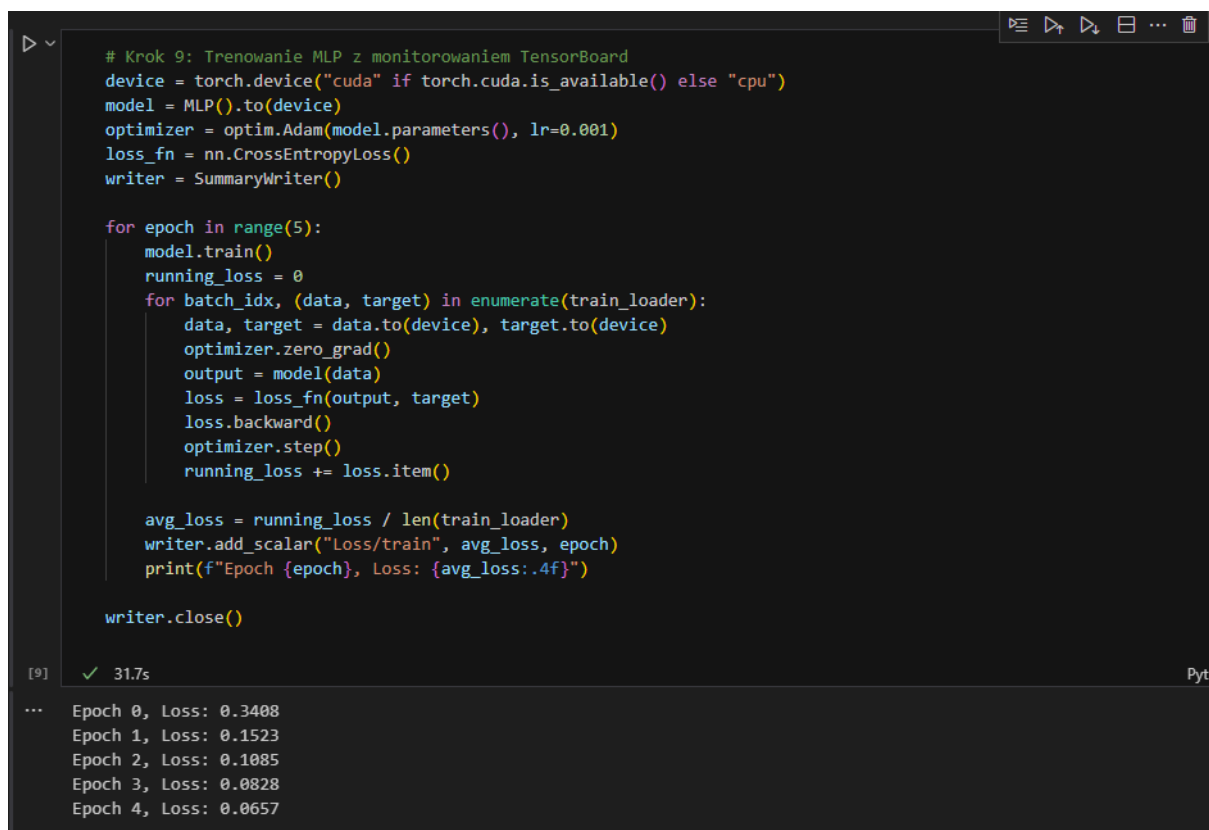
    def forward(self, x):
        x = x.view(-1, 28*28)
        x = self.relu(self.fc1(x))
        x = self.fc2(x)
        return x
```

[8] ✓ 0.0s

Rys. 9. Definicja architektury sieci MLP

9. Trening sieci i monitorowanie w TensorBoard:

Przeprowadzono trening sieci neuronowej z użyciem optymalizatora Adam i funkcji strat CrossEntropyLoss. Na koniec każdego epoki obliczano średnią stratę i zapisywano ją do dziennika TensorBoard, umożliwiając wizualną kontrolę przebiegu procesu uczenia.



```
# Krok 9: Trenowanie MLP z monitorowaniem TensorBoard
device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
model = MLP().to(device)
optimizer = optim.Adam(model.parameters(), lr=0.001)
loss_fn = nn.CrossEntropyLoss()
writer = SummaryWriter()

for epoch in range(5):
    model.train()
    running_loss = 0
    for batch_idx, (data, target) in enumerate(train_loader):
        data, target = data.to(device), target.to(device)
        optimizer.zero_grad()
        output = model(data)
        loss = loss_fn(output, target)
        loss.backward()
        optimizer.step()
        running_loss += loss.item()

    avg_loss = running_loss / len(train_loader)
    writer.add_scalar("Loss/train", avg_loss, epoch)
    print(f"Epoch {epoch}, Loss: {avg_loss:.4f}")

writer.close()
```

[9] ✓ 31.7s

... Epoch 0, Loss: 0.3408
Epoch 1, Loss: 0.1523
Epoch 2, Loss: 0.1085
Epoch 3, Loss: 0.0828
Epoch 4, Loss: 0.0657

Rys. 10. Trening sieci i monitorowanie w TensorBoard.

3. Wnioski

Na podstawie przeprowadzonych eksperymentów można sformułować następujące wnioski. Zmiana współczynnika uczenia miała istotny wpływ na przebieg procesu optymalizacji — dla większych wartości eta (np. 0.01) obserwowano szybszą zbieżność, jednak kosztem większego ryzyka oscylacji lub niestabilności, natomiast mniejsze wartości (np. 0.0001) prowadziły do bardzo wolnego postępu.